实验五 LZW 编码仿真实现

一、 实验目的

- 1. 理解 LZW 算法的原理;
- 2. 编写 MATLAB 程序实现 LZW 编码。

二、 实验原理

1. LZW 算法简介

LZW(Lempel-Ziv-Welch)编码又称"串表压缩算法",是 Welch 将 Lempel 和 Ziv 所提出来的无损压缩技术改进后的压缩方法。该算法通过建立一个字符串表,用较短的码字来表示较长的字符串来实现压缩。下面是 LZW 编码的思路: 考虑一段字符串数据'abcabcabc',假设原始字典如下表所示,每个字符需要一个字节(byte)的存储空间,则经过字典编码后得到的结果用十进制表示为 123123123,直接存储的空间需要 9 个字节。

字符	十进制编号	二进制编号	存储空间
a	1	0000 0001	1 byte
b	2	0000 0010	1 byte
c	3	0000 0011	1 byte

再次观察上面的字符串,可以发现'abc'是重复的,如果'abc'能在字典中用一个字节来表示的话,那么,只需要3字节就能够存储上面的字符串。

下表是我们新建的一个字典:

字符	十进制编号	二进制编号	存储空间
abc	1	0000 0001	1 byte

通过上面的字典,对字符串数据 'abcabcabc' 经过字典编码后得到的十进制结果为 111,只需要 3 字节就可以存储了。

LZW 算法就是对上述过程的一种改进。

2. LZW 编码基本思想

LZW 编码的基本思想如下,首先我们需要初始化一个字典,里面保存了待编码的字符串中所有第一次出现的单个字符和对应的编号,比如 0-9, a-z, A-Z 这些,通常用十进制数 0-255 对单个字符进行编号,或者也可以使用字符在 ASCII

1

表中的编号。字典准备好之后,开始读取字符串,很显然对于任何常规字符串,每个单一字符都可以得到一个码字,但是如果我们不做处理的话,那么对 n 个字符进行编码后,就得到了 n 个码字,原始字符串完全没有被压缩。所以,在读取每个字符的时候,同时开始对字典进行扩充,不断的将单一字符拼接成字符串,成为字典中不存在的符号,并将拼接的字符串扩充进字典,这样下次再遇到这样的字符组合,就可以仅使用一个编号表示了,从而对原始数据进行了压缩。

3. LZW 编码流程

LZW 编码的具体步骤如下:

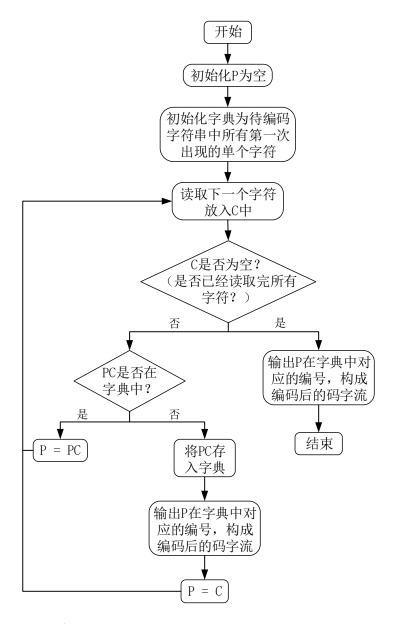
- (1) 初始词典包含待编码字符串中所有第一次出现的单个字符及其编号,这 里可以从数字1开始按顺序向后编号,前缀字符(P)初始化设置为空;
- (2) 当前读取字符(C) = 待编码字符串中的下一个字符;
- (3) 判断字符串(PC)是否在字典中;
 - 如果"是":

P = PC: // 将 P 和 C 合并为一个字符串赋值给 P:

- 如果"否":
 - ① 将 P 和 C 合并为一个整体 PC 并将其添加到词典;
 - ② 输出 P 在字典中对应的编号,构成编码后的码字流;
 - ③ $\Rightarrow P = C$; // 将 C 赋值给 P;
- (4) 判断待编码字符串中是否还有字符需要编码;
 - 如果"是": 返回到步骤(2);
 - 如果"否":
 - ① 输出 P 在字典中对应的编号,构成编码后的码字流:
 - ② LZW 编码结束。

LZW 编码的流程图如下所示:

其中,P表示 Previous,用来存储之前的字符,C表示 Current,用来存储当前读取的字符。



4. LZW 编码示例分析

考虑字符串'abcbcabcabcd',按照上述编码步骤演示一遍 LZW 编码过程: 首先,我们需要一个字典,初始字典只保存了字符串中所有第一次出现的单个字符 a-d,编号分别设为 1-4,如下图所示:

字符	编号
a	1
b	2
С	3
d	4

下面是具体的编码过程,即按照实验原理中的 LZW 编码流程图或编码步骤 对字符串进行编码。

步数	P	C	PC 在字典中?	输出 P	字典	描述
1	NULL	a	yes			a 在字典中,P=PC
2	a	b	no	1	ab:5	ab 不在字典中,扩充进字典,输出 P 的编号
3	b	c	no	2	bc:6	bc 不在字典中,扩充进字典,输出 P 的编号
4	с	b	no	3	cb:7	cb 不在字典中,扩充进字典,输出 P 的编号
5	b	c	yes			bc 在字典中,P=PC
6	bc	a	no	6	bca:8	bca 不在字典中,扩充进字典,输出 P 的编号
7	a	b	yes			ab 在字典中,P=PC
8	ab	c	no	5	abc:9	abc 不在字典中,扩充进字典,输出 P 的编号
9	c	a	no	3	ca:10	ca 不在字典中,扩充进字典,输出 P 的编号
10	a	b	yes			ab 在字典中,P=PC
11	ab	с	yes			abc 在字典中,P=PC
12	abc	d	no	9	abcd:11	abcd 不在字典中,扩充进字典,输出 P 的编号
13	d	NULL		4		结束, 输出 P 的编号

经过上面的演算过程,编码结束后得到的输出码字流为:12365394字典也被扩充为:

字符	编号
a	1
ь	2
С	3
d	4
ab	5
bc	6
cb	7
bca	8
abc	9
ca	10
abcd	11

5. 实验可能用到的 Matlab Function 和数据类型(仅供参考)input(), strcmp(), find(), strcat(), cell 型数据类型等。

三、 实验预习

回答以下问题:

- 1. 假设有一字符串为"abcabcabc",参考实验内容中的 LZW 编码示例分析部分,回答以下问题。
- (1) 写出初始字典。
- (2) 对上述字符串进行 LZW 编码, 仿照实验内容中的 LZW 编码示例分析 部分, 画出表格。
- (3) 写出经过 LZW 编码后得到的码字流和被扩充的字典。

四、 **实验内容**(要求给出结果截图,源代码放在.m文件中)

1. 按照实验原理中的 LZW 编码流程,用 MATLAB 软件编写程序实现对任 意给定的字符串进行 LZW 编码。要求最终在控制台依次输出初始字典,字符串经过 LZW 编码后的码字流和扩充后的字典,并和实验预习中的 计算的结果进行比较。

五、 实验思考题

- 1. 按照 LZW 编码流程,在哪些情况下需要输出 P 中的字符(或字符串) 在字典中对应的编号,构成编码后的码字流?
- 2. 试列举一个只包含'a', 'b', 'c', 'd'四种字符的待编码字符串,要求待编码字符串占用的存储空间为 10bytes, 经过 LZW 编码后得到的码字占用的存储空间为 7bytes。(假设字符串中每个单个字符分别占用 1byte 存储空间,字典中每个元素分别占用 1byte 存储空间。)

实验六 线性分组码仿真实现

一、 实验目的

- 1. 掌握线性分组码的基本原理与编译码算法;
- 2. 学习使用 MATLAB 软件实现线性分组码编译过程:
- 3. 学习使用 MATLAB 软件绘制 (7, 4) 汉明码经 AWGN 信道传输后的误码率曲线,并对其进行性能分析。(扩展实验)

二、实验原理

1. 线性分组码的基本原理

分组码的基本思想是对信息序列进行分组编码。对包含 k 个码元的码组 $M=(m_{k-1},m_{k-2},\ldots,m_1,m_0)$ 按照一定的编码规则产生包含 n 个码元的码组 $C=(c_{n-1},c_{n-2},\ldots,c_1,c_0)$,编码规则定义为:

$$\begin{cases} c_0 = f_0\left(m_{k-1}, m_{k-2},, m_1, m_0\right) \\ c_1 = f_1\left(m_{k-1}, m_{k-2},, m_1, m_0\right) \\ ... \\ c_{n-1} = f_{n-1}\left(m_{k-1}, m_{k-2},, m_1, m_0\right) \end{cases}$$

若 $f_i(\cdot)(i=0,1,...n-1)$ 均为线性函数,则称 C 为线性分组码,一般用(n, k)表示,其中 n 表示码组长度,k 为码组中信息码元长度,r=n-k 为码组中监督码元长度。

实际上,(n, k) 线性分组码是 q 元有限域 GF(q)上 n 维线性空间 V_n 中的一个 k 维子空间 $V_{n,k}$ 。若信息码组 M 与码组 C 的所有元素均取自二元有限域 GF(2) (即 $\{0,1\}$),则称为二元线性分组码。**以下仅讨论二元码的情况。**

2. 线性分组码的编码: 生成矩阵与校验矩阵

对于二元线性分组码,其编码过程实际上就是从包含 2^k 个信息码组的 V_k 空间到包含 2^n 个码组的 V_n 空间的映射过程,因此在码空间 $V_{n,k}$ 中一定可以找到一组基底 $g_0, g_1, \cdots g_{k-1}$,使得所有码组都可以写成这 k 个基底的线性组合,即

$$C = m_{k-1} \mathbf{g}_{k-1} + m_{k-2} \mathbf{g}_{k-2} + \dots + m_1 \mathbf{g}_1 + m_0 \mathbf{g}_0$$

这种线性组合特性正是线性分组码名称的来历。显然,研究线性分组的关键 是研究基底、子空间和映射规则,如图 1 所示。

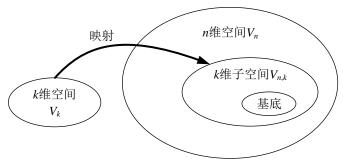


图 1 码空间与映射

用 $g_{i}=(g_{i,n-1},g_{i,n-2},\ldots,g_{i,1},g_{i,0})$ 表示第 $i(i=0,1,\ldots k-1)$ 个基底,再将 k 个基底排列成 k 行 n 列矩阵的形式,即

$$G = \begin{bmatrix} \mathbf{g}_{k-1} \\ \vdots \\ \mathbf{g}_{1} \\ \mathbf{g}_{0} \end{bmatrix} = \begin{bmatrix} g_{k-1,n-1} & \cdots & g_{k-1,1} & g_{k-1,0} \\ \vdots & \ddots & \vdots & \vdots \\ g_{1,n-1} & \cdots & g_{1,1} & g_{1,0} \\ g_{0,n-1} & \cdots & g_{0,1} & g_{0,0} \end{bmatrix}$$

由于 k 个基底即 G 的 k 个行矢量线性无关,故矩阵 G 的秩一定等于 k。当信息码组 M 确定后,码组 C 仅由 G 矩阵决定,即 (n,k) 线性分组码中的任一码组 C 均可由这组基底的线性组合生成:

$$C = [m_{k-1}, m_{k-2}, \cdots m_0] \begin{bmatrix} \boldsymbol{g}_{k-1} \\ \vdots \\ \boldsymbol{g}_1 \\ \boldsymbol{g}_0 \end{bmatrix}$$

-MG

因此称这 $k \times n$ 矩阵 G 为该 (n, k) 线性分组码的生成矩阵。

基底不是唯一的,生成矩阵也就不是唯一的。事实上,将 k 个基底线性组合后产生另一组 k 个矢量,只要满足线性无关的条件,依然可以作为基底张成另一个码空间。不同的基底也有可能生成同一个码组,但因编码涉及码组和映射两个因素,即使码组相同而映射方法不同也不能认为是同样的码。

基底的线性组合等效于生产矩阵 G 的行运算,能够产生一组新的基底。利用矩阵的行运算可使生产矩阵具有如下的"系统形式":

$$\boldsymbol{G} = \begin{bmatrix} \boldsymbol{I}_k & \boldsymbol{P} \end{bmatrix} = \begin{bmatrix} 1 & 0 & \cdots & 0 & & p_{k-1,n-k-1} & \cdots & p_{k-1,1} & p_{k-1,0} \\ 0 & 1 & \cdots & 0 & & p_{k-2,n-k-1} & \cdots & p_{k-2,1} & p_{k-1,0} \\ \vdots & \vdots & \ddots & \vdots & & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & & p_{0,n-k-1} & \cdots & p_{0,1} & p_{0,0} \end{bmatrix}$$

其中P为 $k \times (n-k)$ 矩阵, I_k 为 $k \times k$ 单位矩阵,从而保证矩阵G的秩为k。对于系统码,有

$$C = MG = [M \quad MP]$$

根据线性代数知识,生成矩阵 G 是由 k 个线性无关的行向量构成的,因此

一定存在一个由 n-k 的线性无关的行向量构成的矩阵 H 与之相交,即 $GH^{T}=0$ 。 对于"系统形式"的生成矩阵 G,其校验矩阵 H 也是规则的:

$$\boldsymbol{H} = \begin{bmatrix} -\boldsymbol{P}^{\mathrm{T}} & \boldsymbol{I}_{n-k} \end{bmatrix}$$

对于二元码,由于模二减法等同于模二加法,上式的负号可以省略。

3. 线性分组码的距离与纠检错能力

在分组码中,把码组中"1"的数目称为码组的重量,简称码重;把两个码组中对应位置上数字不同的位数称为码组的距离,简称码距,又称汉明距离,记为 d。某种编码算法中各个码组之间距离的最小值称为最小码距:

$$d_0 = \min \left\{ d_{C_i C_j}, i \neq j, C_i, C_j \in V_{n,k} \right\}$$

两个码组之间的距离表示它们之间差别的大小: 距离越大, 两个码组的差别越大, 传输时从一个码组错成另一码组的可能性越小, 抗干扰能力越强。估算最小码距是纠错码设计的重要步骤, 原始方案是逐一计算两两码组之间的距离, 找到其中的最小值; 然而若每个码集有 2^k 个许用码组, 就需要计算 2^k (2^k -1)/2 个距离, 计算量太大。

利用线性分组码的封闭性: 任意两个码组之和仍为许用码组,即

$$C_i + C_j = C_m \in C$$

因此任意两个码组之间的码距就是另一码组的码重,表达式如下:

$$d_{C_iC_i} = w(C_i + C_j) = w(C_m)$$

式中 $w(C_m)$ 表示码组 C_m 的码重。最小码距为 d_0 可表示为:

$$d_0 = \min \left\{ w(C_m), C_m \in V_{n,k}, C_m \neq 0 \right\}$$

将计算最小码距问题转化成寻找最轻码字问题,若每个码集有 2^k 个许用码组、仅需计算 2^k 次。

对于最小码距为 d_0 的线性分组码, 其检错能力 $e=d_0-1$, 纠错能力:

$$t = \left\lfloor \frac{d_0 - 1}{2} \right\rfloor$$

式中1·1表示向下取整。

码的纠错能力取决于码的最小距离,但还需说明的另一点是码的总体纠错能力不仅仅与 d_0 有关。纠错能力 t 只是说明距离 t 以内的差错一定能纠正,并非说距离大于 t 的差错一定不能纠正。事实上,如果每个码集有 2^k 个许用码组,就存在 2^k (2^k -1)/2 个距离,且每个距离并非是相等的。比如最小距离 d_0 =3,纠错能力 t=1:若许用码组 C_2 与 C_1 之间的距离等于最小距离 3,而 C_2 与 C_3 之间的距离大于最小距离 3(此处假设为 5);只要 C_2 朝 C_1 方向的偏差大于 1 就会出现译码错误,然而若 C_2 朝 C_3 方向偏差 2,译码时仍可正确地判断为 C_2 而非 C_3 。可见,总体的、平均的纠错能力不但与最小距离有关,而且与其余码距离或者说与

码组的重量分布特性有关,把码距(码重)的分布特性称为距离(重量)谱,其中最小的重量就是 d_0 。正如信息论各符号等概时熵最大一样,从概念上可以想象到: 当所有码距相等时(重量谱为线谱)码的性能应该最好;或者退一步说,当各码距相差不大时(重量谱为窄谱)性能应该称得上好。事实证明确实如此,在同样的 d_0 条件下,窄谱的码一般比宽谱的码更优。

纠错重量谱的研究具有理论与现实意义,不仅仅是计算各种译码差错概率的主要依据,也是研究码的结构、改善码集内部关系从而发现新的好码的重要工具。但目前除了少数几类码如汉明码、极长码等的重量分布已知外,还有很多码的重量分布并不知道,距离分布与性能之间确切的定量关系对于大部分码而言尚在进一步研究当中,特别当 n 和 k 较大时,要得出码重分布是非常困难的。

4. 线性分组码的译码: 伴随式与错误图样

编码后输出的码组在信道上传输时可能产生一定的码元错误,将这些码元错误称为错误图样。设发送码组为 $C=(c_{n-1},c_{n-2},\ldots,c_1,c_0)$,信道产生的错误图样为 $E=(e_{n-1},e_{n-2},\ldots,e_1,e_0)$,则接收到的码组为 $R=C+E=(r_{n-1},r_{n-2},\ldots,r_1,r_0)$,译码器的作用就是根据接收到的码组 R 来估计错误图样 E,进而得到对发送码组 C 的估计。

对于二元码,模二加法等同于模二减法,故错误图样 E=R-C=R+C。利用码组与校验矩阵 H 的正交性即 $CH^{T}=MGH^{T}=0$,可检验接收码组 R 是否出错:

$$RH^{\mathrm{T}} = (C + E)H^{\mathrm{T}} = CH^{\mathrm{T}} + EH^{\mathrm{T}} = EH^{\mathrm{T}} \begin{cases} = 0 \\ \neq 0 \end{cases}$$

定义伴随式 $S=RH^T=EH^T$,由上式可知伴随式 S 仅与错误图样 E 有关,与发送码组 C 无关:若在信道传输过程中没有错误发生即 E=0,则 S=0:否则 $S\neq 0$ 。

伴随式译码算法的基本思想就是根据伴随式 S 的值来估计错误图样 E。将检验矩阵 H 写成列向量的形式:

$$\boldsymbol{H} = [\boldsymbol{h}_{n-1}, \boldsymbol{h}_{n-2},, \boldsymbol{h}_{1}, \boldsymbol{h}_{0}]$$

则有

$$S = EH^{\mathrm{T}} = \sum_{i=0}^{n-1} e_i h_i^{\mathrm{T}}$$

即伴随式 S 是校验矩阵 H 中列向量的线性组合。对于错误图样 E,码元中第 j 位发生错误时其值 e_j =1,否则 e_j =0。因此伴随式 S 的值实际上是出错码元对应的校验矩阵 H 的列向量的模二和。

在线性分组码的纠错能力范围内,如果能够确定伴随式S的值是校验矩阵H的哪个或哪几个列向量的模二和,就可以确定错误图样E,进而实现译码。

5. 线性分组码编译码示例: 汉明码的编译过程

汉明码是最常见的线性分组码,最小距离 $d_0=3$,纠错能力 t=1,即能够纠正

单个随机错误。以(7,4)汉明码为例,生成矩阵G如下:

$$G = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 1 & 1 \\ 0 & 1 & 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 & 1 & 1 \end{bmatrix}$$

根据 $GH^{T}=0$,校验矩阵 H 为:

$$\boldsymbol{H} = \begin{bmatrix} 1 & 1 & 1 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 1 \end{bmatrix}$$

根据 $C=MG=M[I\ P]=[M\ MP]$,信息码元 M 与监督码元 MP 对应关系如表 1 所示。

- This is a second of the seco					
信息码元	监督码元	信息码元	监督码元		
$(c_6c_5c_4c_3)$	$(c_2c_1c_0)$	$(c_6c_5c_4c_3)$	$(c_2c_1c_0)$		
0000	000	1000	111		
0001	011	1001	100		
0010	101	1010	010		
0011	110	1011	001		
0100	110	1100	001		
0101	101	1101	010		
0110	011	1110	100		
0111	000	1111	111		

表 1 信息码元与监督码元对应关系

根据 $S=RH^T=EH^T$, 伴随式 S 与错误图样 E 的关系如表 2 所示。

伴随式	错误图样	伴随式	错误图样
$(s_2s_1s_0)$	$(e_6e_5e_4e_3e_2\ e_1e_0)$	$(s_2s_1s_0)$	$(e_6e_5e_4e_3e_2\ e_1e_0)$
000	0000000	011	0001000
001	0000001	101	0010000
010	0000010	110	0100000
100	0000100	111	1000000

表 2 伴随式与错误图样对应关系

设输入信息序列 M=(1001), 按表 1进行编码可得:

得到编码输出 C=(1001100)。

设信号在传输时发生错误,得到译码输入序列 $R=(1\ 0\ 0\ 1\ 0\ 0)$,计算伴随式 $S=RH^T=(0\ 1\ 1)$ 。根据表 2 可得错误图样为 $E=(0\ 0\ 0\ 1\ 0\ 0)$,即接收序列第四位 发生错误,纠正后得到正确的发送序列 $C=R+E=(1\ 0\ 0\ 1\ 1\ 0\ 0)$,可知信息序列

 $M = (1\ 0\ 0\ 1)_{\circ}$

6. 实验中可能用到的 Matlab Function (仅供参考)

rem(), reshape(), switch(), randn().

三、 实验预习

回答以下问题:

1. 给定生成矩阵 **G** 如下,请给出信息码元与监督码元对应关系表,并说明 该码的最小距离与纠错能力。

$$G = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 & 1 & 1 \end{bmatrix}$$

2. 依据上题中的生成矩阵 G 计算相应校验矩阵 H,给出伴随式 S 与错误 图样 E 对应关系表。

四、 实验内容 (要求给出结果截图,源代码放在.m 文件中)

给定(7, 4)汉明码生成矩阵G如下:

$$\boldsymbol{G} = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 & 1 & 1 \end{bmatrix}$$

1. 编写 MATLAB 函数(function)实现分组编码:函数输入为生成矩阵 G 与信息序列 M,输出为编码结果 C。(考虑到可能出现输入信息序列无法完整分组的情况,即序列长度不是 k 的整数倍,可在序列末尾适当补零以完整分组。)

当输入信息序列 M=[1011010110]时,输出编码结果。

2. 编写 MATLAB 函数(function)实现该分组码的译码过程:函数输入为生成矩阵 G 与接收序列 R,输出为译码结果。(提示:请先完成实验预习 2,得到伴随式与错误图样对应关系。)

当接收序列 R 分别为发送序列 C 在未发生错误、发生一位错误、发生两位错误的情况下得到时,输出译码结果。

3. 在 AWGN 信道传输与 BPSK 调制的条件下,绘制未编码系统与(7,4) 汉明编码系统的误码率曲线。信噪比范围: 0~10dB,参考流程图见图 2。(扩展实验)

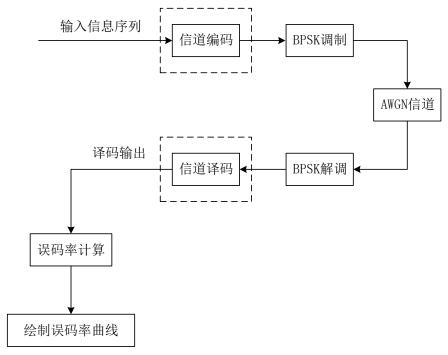


图 2 信道编码系统的实现流程图

五、 实验思考题

- 1. 对比分析发送序列分别在未发生错误、发生一位错误、发生两位错误情况下得到的接收序列 R 的译码结果。
- 2. 对比分析在 AWGN 信道传输与 BPSK 调制的条件下,未编码系统与(7,4) 汉明编码系统的误码性能。